

**SVEUČILIŠTE U ZAGREBU**  
**PRIRODOSLOVNO–MATEMATIČKI FAKULTET**  
**MATEMATIČKI ODSJEK**

Mihael Petrinjak

**SEGMENTIRANA METODA**  
**NAJMANJIH KVADRATA**

Zagreb, prosinac 2022.

# Sadržaj

<b>Sadržaj</b>	<b>ii</b>
<b>Uvod</b>	<b>1</b>
<b>1 Problem</b>	<b>2</b>
1.1 Motivacija . . . . .	2
1.2 Matematička formulacija . . . . .	3
<b>2 Algoritam</b>	<b>4</b>
2.1 Princip optimalnosti . . . . .	4
2.2 Pseudokod . . . . .	6
2.3 Složenost algoritma . . . . .	7
<b>Bibliografija</b>	<b>8</b>

# Uvod

Ovaj rad je projektni zadatak za kolegij *Oblikovanje i analiza algoritama*. Znanje preuzeto iz [1].

# Poglavlje 1

## Problem

### 1.1 Motivacija

Klasičan problem u analizi podataka je aproksimacija točaka u ravni pravcem. Ima dobro nam poznato rješenje koje se efikasno računa iz danih podataka.

Neka je  $P$  skup točaka  $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$  takav da  $x_1 < x_2 < \dots < x_n$ . Znamo da funkciju

$$E(L, P) = \sum_i (y_i - ax_i - b)^2 \quad (1.1)$$

minimiziraju

$$a = \frac{n \sum_i x_i y_i - (\sum_i x_i)(\sum_i y_i)}{n \sum_i x_i^2 - (\sum_i x_i)^2} \quad b = \frac{\sum_i y_i - a \sum_i x_i}{n} \quad (1.2)$$

Skup  $P$  ne mora biti lijep. Može se dogoditi da točke ne izgledaju kao da leže u blizini nekog pravca ili da postoji nekoliko pravaca koji dobro aproksimiraju zadani skup. Naravno, želimo formulaciju koja ne zahtjeva vizualizaciju podataka kako bismo odredili optimalan broj pravaca.

## 1.2 Matematička formulacija

Kao i gore  $P = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\} = \{p_1, p_2, \dots, p_n\}$  i  $x_1 < x_2 < \dots < x_n$ . **Segment** u  $P$  je skup oblika  $\{p_i, p_{i+1}, \dots, p_j\}$  gdje  $1 \leq i \leq j \leq n$ . Tražimo particiju  $F$  skupa  $P$  koja se sastoji isključivo od segmenata u  $P$ . Za svaki  $S \in F$  računamo minimalnu pogrešku aproksimacije po formulama (1.2) i (1.1).

**Penalizacija** particije  $F$  se definira kao suma sljedećih izraza.

- (i) Broj segmenata u  $F$  pomnožen s konstantom  $C > 0$ .
- (ii) Za svaki segment  $S \in F$  vrijednost  $E(L, S)$  gdje je  $L$  pravac dobiven *metodom najmanjih kvadrata*.

$E(L, S)$  je minimalna greška za proizvoljni pravac na segmentu  $S$ . Povećanjem broja segmenata raste vrijednost izraza (i) i pada vrijednost (ii). za smanjenje broja segmenata vrijedi obratno. Konstanta  $C$  modelira cijenu dodavanja segmenta u particiju. Veći  $C$  znači manji broj segmenata u rješenju.

Cilj *Segmentirane metode najmanjih kvadrata* je naći particiju minimalne penalizacije.

## Poglavlje 2

# Algoritam

### 2.1 Princip optimalnosti

Neka  $OPT(n)$  predstavlja optimalno rješenje na točkama  $p_1, \dots, p_n$  i neka je  $e_{i,j}$  vrijednost  $E(L(a, b), \{p_i, \dots, p_j\})$  gdje su  $a, b$  dobiveni iz (1.2), tj. minimalna greška aproksimacije pravcem. Primijetimo sljedeće.

**Slutnja 2.1.1.** *Ako je zadnji segment optimalne particije  $\{p_i, \dots, p_n\}$ , onda je vrijednost optimalnog rješenja jednaka  $OPT(n) = e_{i,n} + C + OPT(i - 1)$*

Problem je time sveden na manji. Primjenom istog pristupa opravdavamo sljedeću generaliziranu rekurziju.

**Teorem 2.1.2.** *Optimalno rješenje podproblema na  $\{p_1, \dots, p_j\}$  dano je s*

$$OPT(j) = \min_{1 \leq i \leq j} (e_{i,j} + C + OPT(i - 1)) \quad (2.1)$$

uz početni uvjet  $OPT(0) = 0$ .

*Dokaz.* Jakom indukcijom po  $j$ .

**Baza:**

$$OPT(1) = e_{1,1} + C + OPT(0) = 0 + C + 0 = C$$

Budući da je najmanji mogući broj segmenata jednak jedan, ovo je minimalna vrijednost za  $\{p_1\}$ .

**Pretpostavka:** Optimalno rješenje na  $\{p_1, \dots, p_k\}$  dano je s

$$OPT(k) = \min_{1 \leq i \leq k} (e_{i,k} + C + OPT(i - 1)),$$

za svaki  $k \in \mathbb{N}, k < j$

**Korak:**

$$OPT(j) = \min \begin{cases} e_{1,j} + C + OPT(0), \\ e_{2,j} + C + OPT(1), \\ \vdots \\ e_{j,j} + C + OPT(j-1) \end{cases} \quad (2.2)$$

Jedina odluka je postavljanje indeksa  $i$  na odgovarajuće mjesto. U svakom retku izraza (2.2) se po pretpostavci nalazi minimalna vrijednost penalizacije lijevih segmenata za takav izbor indeksa  $i$ . Izbor najmanje vrijednosti daje optimalno rješenje za  $p_1, \dots, p_j$ .

□

## 2.2 Pseudokod

---

**Algorithm 1** Segmentirana metoda najmanjih kvadrata
 

---

```

1: procedure SMNK( $P, n, C$ )
2:   Polje  $OPT[0...n]$ 
3:    $OPT[0] \leftarrow 0$ 
4:   Matricu  $E[1...n][1...n]$  inicijaliziraj na (0).
5:   for svi parovi  $i \leq j$  do
6:      $E[i][j] \leftarrow e_{i,j}$ 
7:   end for
8:   for  $1 \leq j \leq n$  do
9:     Računaj  $OPT[j]$  po rekurziji u teoremu 2.1.2
10:  end for
11: return  $OPT$ 
12: end procedure

1: procedure IZVADI SEGMENTE( $OPT, j, C$ )
2:   if  $j = 0$  then
3:     Gotovo.
4:   else
5:     Pronađi  $i$  koji minimizira  $e_{i,j} + C + OPT[i - 1]$ .
6:     return  $\{p_i, \dots, p_j\}$ 
7:     return IZVADI SEGMENTE( $OPT, i - 1, C$ )
8:   end if
9: end procedure

1: procedure MAIN
2:    $P, n, C$  zadani.
3:    $OPT \leftarrow \text{SMNK}(P, n, C)$ 
4:    $particija \leftarrow \text{IZVADI SEGMENTE}(OPT, n, C)$ 
5: end procedure

```

---



## 2.3 Složenost algoritma

Vrijeme potrebno za računanje (1.2) i (1.1) je  $\Theta(n)$ . Dakle, za  $e_{i,j}$  potrebno je  $\Theta(n)$  operacija. Parova  $1 \leq i \leq j \leq n$  je  $\Theta(n^2)$ . Nakon  $O(n^3)$  vremena imamo sve vrijednosti  $e_{i,j}$ . Složenost traženja minimuma u devetom retku algoritma traje  $O(n)$  i to za  $n$  vrijednosti parametra  $j$ . Složenost SMNK je  $O(n^2)$ .

Svako izvlačenje segmenata bez rekurzivnog poziva traje  $O(n)$ . U najgorem slučaju  $\frac{n}{2}$  puta pa segmente pronalazimo u  $O(n^2)$  vremena.

# Bibliografija

- [1] Jon Kleinberg i Eva Tardos, *Algorithm design*, Addison Wesley, 2006.